2018/7/22 hihoCoder

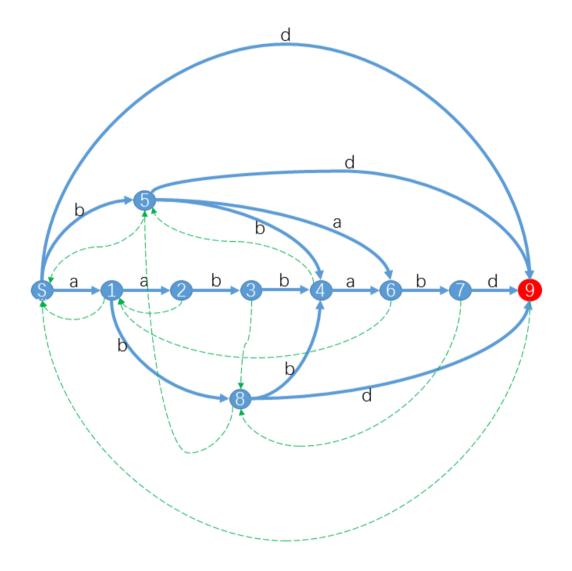
题目1:后缀自动机一·基本概念

时间限制: 10000ms 单点时限: 1000ms 内存限制: 256MB

描述

小Hi: 今天我们来学习一个强大的字符串处理工具:后缀自动机(Suffix Automaton,简称SAM)。**对于一个字符串S,它对应的后缀自动机是一个最小的确定有限状态自动机(DFA),接受且只接受S的后缀。**

小Hi: 比如对于字符串S="aabbabd", 它的后缀自动机是:



其中红色状态是终结状态。你可以发现对于S的后缀,我们都可以从S出发沿着字符标示的路径(蓝色实线)转移,最终到达终结状态。例如"bd"对应的路径是S59,"abd"对应的路径是S189,"abbabd"对应的路径是S184679。而对于不是S后缀的字符串,你会发现从S出发,最后会到达非终结状态或者"无路可走"。特别的,对于S的子串,最终会到达一个合法状态。例如"abba"路径是S1846,"bbab"路径是S5467。而对于其他不是S子串的字符串,最终会"无路可走"。例如"aba"对应S18X,"aaba"对应S123X。(X表示没有转移匹配该字符)

小Ho: 好像很厉害的样子! 对于任意字符串都能构造出一个SAM吗? 另外图中那些绿色虚线是什么?

小Hi: 是的,任意字符串都能构造出一个SAM。我们知道SAM本质上是一个DFA,DFA可以用一个五元组**〈字符集,状态集,转移函数、起始状态、终结状态集〉**来表示。下面我们将依次介绍对于一个给定的字符串S如何确定它对应的 **状态集** 和 **转移函数** 。至于那些绿色虚线虽然不是DFA的一部分,却是SAM的重要部分,有了这些链接SAM是如虎添翼,我们后面再细讲。

SAM的States

小Hi: 这一节我们将介绍给定一个字符串S,如何确定S对应的SAM有哪些状态。首先我们先介绍一个概念 **子串的结束位置集合** endpos。对于S的一个子串s,endpos(s) = s在S中所有出现的结束位置集合。还是以S="aabbabd"为例,endpos("ab") = {3, 6},因为"ab"一共出现了2次,结束位置分别是3和6。同理endpos("a") = {1, 2, 5}, endpos("abba") = {5}。

2018/7/22 hihoCoder

小Hi: 我们把S的所有子串的endpos都求出来。如果两个子串的endpos相等,就把这两个子串归为一类。最终这些endpos的等价类就构成的SAM的状态集合。例如对于S="aabbabd":

状态	子串	endpos
S	空串	{0,1,2,3,4,5,6}
1	а	{1,2,5}
2	aa	{2}
3	aab	{3}
4	aabb,abb,bb	{4}
5	b	{3,4,6}
6	aabba,abba,bba,ba	{5}
7	aabbab,abbab,bbab,bab	{6}
8	ab	{3,6}
9	aabbabd,abbabd,bbabd,babd,abd,bd,d	{7}

小Ho: 这些状态恰好就是上面SAM图中的状态。

小Hi: 没错。此外,这些状态还有一些美妙的性质,且等我——道来。首先对于S的两个子串s1和s2,不妨设length(s1) <= length(s2),那么 **s1是s2 的后缀当且仅当endpos(s1)** ⊇ **endpos(s2)**,**s1不是s2的后缀当且仅当endpos(s1)** ∩ **endpos(s2)** = Ø。

小Ho: 我验证一下啊... 比如"ab"是"aabbab"的后缀,而endpos("ab")={3,6},endpos("aabbab")={6},是成立的。"b"是"ab"的后缀,endpos("b")={3,4,6},endpos("ab")={3,6}也是成立的。"ab"不是"abb"的后缀,endpos("ab")={3,6},endpos("abb")={4},两者没有交集也是成立的。怎么证明呢?

小Hi: 证明还是比较直观的。首先证明s1是s2的后缀=>endpos(s1) ⊇ endpos(s2): 既然s1是s2后缀,所以每次s2出现时s1以必然伴随出现,所以有endpos(s1) ⊇ endpos(s2)。再证明endpos(s1) ⊇ endpos(s2)=>s1是s2的后缀: 我们知道对于S的子串s2, endpos(s2)不会是空集,所以endpos(s1) ⊇ endpos(s2)=>存在结束位置x使得s1结束于x,并且s2也结束于x,又length(s1) <= length(s2),所以s1是s2的后缀。综上我们可知s1是s2的后缀当且仅当endpos(s1) ⊇ endpos(s2)。s1不是s2的后缀当且仅当endpos(s1) ∩ endpos(s2) = Ø是一个简单的推论,不再赘述。

小Ho: 我好像对SAM的状态有一些认识了! 我刚才看上面的表格就觉得SAM的一个状态里包含的子串好像有规律。考虑到SAM中的一个状态包含的子串都具有相同的endpos, 那它们应该都互为后缀?

小Hi: 你观察力还挺敏锐的。下面我们就来讲讲一个状态包含的子串究竟有什么关系。上文提到我们把S的所有子串按endpos分类,每一类就代表一个状态,所以我们可以认为一个状态包含了若干个子串。我们用substrings(st)表示状态st中包含的所有子串的集合,longest(st)表示st包含的最长的子串,shortest(st)表示st包含的最短的子串。例如对于状态7,substring(7)={aabbab,abbab,bbab,bab}, longest(7)=aabbab,shortest(7)=bab。

小Hi: **对于一个状态st,以及任意s**∈**substrings(st),都有s是longest(st)的后缀。**证明比较容易,因为endpos(s)=endpos(longest(st)),所以endpos(s) ⊇ endpos(longest(st)),根据我们刚才证明的结论有s是longest(st)的后缀。

小Hi: 此外,**对于一个状态st,以及任意的longest(st)的后缀s,如果s的长度满足:** length(shortest(st)) <= length(s) <= length(s) <= length(longsest(st)), **那么s**∈substrings(st)。 证明也是比较容易,因为: length(shortest(st)) <= length(s) <= length(longsest(st)),所以endpos(shortest(st)) = endpos(shortest(st)) = endpos(sho

小Ho: 这么说来, substrings(st)包含的是longest(st)的一系列连续后缀?

小Hi: 没错。比如你看状态7中包含的就是aabbab的长度分别是6,5,4,3的后缀;状态6包含的是aabba的长度分别是5,4,3,2的后缀。

SAM的Suffix Links

小Hi: 前面我们讲到substrings(st)包含的是longest(st)的一系列**连续**后缀。这连续的后缀在某个地方会"断掉"。比如状态7,包含的子串依次是 aabbab,abbab,bbab,bab。按照连续的规律下一个子串应该是"ab",但是"ab"没在状态7里,你能想到这是为什么么?

小Ho: aabbab,abbab,bbab,bab的endpos都是{6},下一个"ab"当然也在结束位置6出现过,但是"ab"还在结束位置3出现过,所以"ab"比 aabbab,abbab,bbab,bbab,bab出现次数更多,于是就被分配到一个新的状态中了。

小Hi: 没错,当longest(st)的某个后缀s在新的位置出现时,就会"断掉",s会属于新的状态。比如上例中"ab"就属于状态8,endpos("ab"}={3,6}。当我们进一步考虑"ab"的下一个后缀"b"时,也会遇到相同的情况:"b"还在新的位置4出现过,所以endpos("b")={3,4,6},b属于状态5。在接下去处理"b"的后缀我们会遇到空串,endpos("")={0,1,2,3,4,5,6},状态是起始状态S。

2018/7/22 hihoCoder

小Hi: 于是我们可以发现一条状态序列: 7->8->5->S。这个序列的意义是longest(7)即aabbab的后缀依次在状态7、8、5、S中。我们用Suffix Link这一串状态链接起来,这条link就是上图中的绿色虚线。

小Ho: 原来如此。

小Hi: Suffix Links后面会有妙用,我们暂且按下不表。

SAM的Transition Function

小Hi: 最后我们来介绍SAM的转移函数。对于一个状态st,我们首先找到从它开始下一个遇到的字符可能是哪些。我们将st遇到的下一个字符集合记作next(st),有next(st) = {S[i+1] | i ∈ endpos(st)}。例如next(S)={S[1], S[2], S[3], S[4], S[5], S[6], S[7]}={a, b, d}, next(8)={S[4], S[7]}={b, d}。

小Hi: 对于一个状态st来说和一个next(st)中的字符c, 你会发现substrings(st)中的所有子串后面接上一个字符c之后, 新的子串仍然都属于同一个状态。比如对于状态4, next(4)={a}, aabb,abb,bb后面接上字符a得到aabba, abba, bba, 这些子串都属于状态6。

小Hi: 所以我们对于一个状态st和一个字符c∈next(st),可以定义转移函数trans(st, c) = x | longest(st) + c ∈ substrings(x)。换句话说,我们在 longest(st) (随便哪个子串都会得到相同的结果)后面接上一个字符c得到一个新的子串s,找到包含s的状态x,那么trans(st, c)就等于x。

小Ho: 吼~终于把SAM中各个部分搞明白了。

小Hi: SAM的构造有时空复杂度均为O(length(S))的算法,我们将在后面介绍。这一期你可以先用暴力算法依照定义构造SAM,先对SAM有个直观 认识再说

小Ho: 没问题,暴力算法我最拿手了。我先写程序去了。

输入

第一行包含一个字符串S, S长度不超过50。

第二行包含一个整数N,表示询问的数目。(1 <= N <= 10)

以下N行每行包括一个S的子串s,s不为空串。

输出

对于每一个询问s,求出包含s的状态st,输出一行依次包含shortest(st)、longest(st)和endpos(st)。其中endpos(st)由小到大输出,之间用一个空格分割。

样例输入

```
aabbabd
5
b
abbab
aa
aabbab
bb
```

样例输出

```
b b 3 4 6
bab aabbab 6
aa aa 2
bab aabbab 6
bb aabb 4
```